

```
#Datensatz einlesen
ChristmasSales = pd.read_csv("Christmas Sales and Trends.csv")
ChristmasSales = pd.read_excel("Christmas Sales and Trends.xlsx")
#Ansich Datensatz erste und letzte Zeilen
display(ChristmasSales.head(3))
display(ChristmasSales.tail(3))

#mit .describe können die metrischen Merkmale ausgegeben werden
ChristmasSales.describe()

# allgemeine infos zum Datensatz
display(datensatz.info())
```

```
# ECDF PLOT (Empirische Verteilungsfunktion)
# Zeigt den kumulierten Anteil der Datenpunkte bis zu einem Wert.
# Die Kurve startet bei 0 und endet bei 1. Bei 0.5 auf der y-Achse liegt der Median.
# Einstellungen: x=Spalte, hue=Vergleich von Gruppen
sn.ecdfplot(data=df, x='length', hue='group')
plt.show()

# BOXPLOT (Gruppenvergleich)
# Visualisiert Median, Quartile und Ausreißer. Boxen zeigen die Streuung.
# Überlappen sich Boxen nicht, liegen signifikante Unterschiede nahe.
# - Mittellinie: Median
# - Box-Kanten: Q1 (25%) und Q3 (75%). Die Box enthält 50% der Daten.
# - Whiskers: Gehen bis zum letzten Datenpunkt innerhalb von 1.5 * IQR.
# - Punkte: Ausreißer außerhalb der Whisker-Grenzen.
sn.boxplot(data=df, x=Kategorie, y=Messwert, hue=Farbe pro Gruppe)
plt.show()
```

```
# HISTOGRAMM (Dichteverteilung)
# Stellt Häufigkeiten in Klassen dar. Prüft die Normalverteilung.
# Einstellungen: bins=Anzahl der Balken, kde=True (zeichnet Glättungslinie)
sn.histplot(df['length'], kde=True, bins=30)
plt.show()

# COUNTPLOT (Absolute Häufigkeit)
# Erstellt Balkendiagramme für kategoriale Daten (wie Gruppen oder Ja/No).
# Zeigt direkt an, welche Kategorie am häufigsten vorkommt.
# Einstellungen: x=Spalte
sn.countplot(data=df, x='group')
plt.show()

# BARPLOT (Relative Häufigkeit/Mittelwerte)
# Zeigt Anteile oder Durchschnittswerte pro Gruppe.
# Einstellungen: x=Gruppe, y=Wert, estimator=np.mean oder len
sn.barplot(data=df, x='group', y='length', estimator=len)
plt.show()

# REGPLOT (Streudiagramm mit Trend)
# Zeigt den linearen Zusammenhang zwischen zwei numerischen Werten.
# Punkte nah an der Linie bedeuten eine hohe Korrelation.
# Einstellungen: x=Variable 1, y=Variable 2
sn.regplot(data=df, x='Accept', y='Apps')
plt.show()

# HEATMAP (Korrelationsübersicht)
# Farbmatrix der Zusammenhänge. Werte nahe 1 zeigen starke Bindung.
# Erfordert numerische Daten. Filtert Textspalten vorher aus.
# Einstellungen: annot=True (schreibt Zahlen in Felder), cmap=Farbschema
sn.heatmap(df.corr(numeric_only=True), annot=True, cmap='RdBu')
plt.show()

# PAIRPLOT (Multivariate Analyse)
# Erstellt eine Matrix aller Variablenkombinationen.
# Hilft beim Finden von Mustern in großen Datensätzen.
# Einstellungen: kind='reg' (fügt Regressionslinien in jedes Feld ein)
sn.pairplot(df.select_dtypes('number'), kind='reg')
plt.show()
```

```
# --- DATENBEREINIGUNG
# Zeilen mit fehlenden Werten löschen
df = df.drop()
df = df.drop_duplicates(keep='first')

# --- STICHPROBENUMFANG (Wie viele Messungen brauche ich?) ---
# z=1.96 (für 95% Sicherheit), sigma=bekannte Streuung, e=erlaubte Abweichung
z = 1.96
e = 0.05
n_notwendig = ((z * sigma) / e)**2
print(f"Benötigtes n: {np.ceil(n_notwendig)}")

# --- SKALIERUNG / STANDARDISIERUNG (Pinguin Übung) ---
# Daten auf Mittelwert 0 und Std 1 bringen (Z-Transformation)
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
df_scaled = scaler.fit_transform(df[['length', 'weight']])
```

```
REGRESSION & MODELLGÜTE
P-Wert (P>|t|): < 0.05 -> Merkmal ist signifikant (wichtig).

R-squared: Anteil erklärter Varianz (0 bis 1). Je höher, desto besser.

F-Statistik: Modell insgesamt brauchbar (wenn Prob < 0.05).
F-Statistik prüft ebenfalls Nullhypothese (dass alle Koeffizienten gleich Null sind)

R2-adj (0.91): 91% Varianz kann durch die unabhängigen Merkmale im Modell erklärt werden
Die Vorhersagen liegen nah an den tatsächlichen Werten.
Adjustiert: Korrigiert um Variablenanzahl (verhindert Schoenrechnen).
```

```
# --- SATZ VON BAYES (Beispiel: Restaurant Ratte) ---
# Berechne die Wahrscheinlichkeit für eine Ratte, wenn eine schlechte Bewertung vorliegt.

# Gegebene Wahrscheinlichkeiten
p_ratte = 0.10 # 10% der Restaurants haben Ratten (P(A))
p_schlecht_bei_ratte = 0.80 # 80% bekommen schlechte Bewertung, WENN Ratte da ist (P(B|A))
p_schlecht_ohne_ratte = 0.20 # 20% bekommen schlechte Bewertung, WENN KEINE Ratte da ist (P(B|nicht A))

# 1. Totale Wahrscheinlichkeit für eine schlechte Bewertung berechnen (P(B))
p_schlecht_total = (p_schlecht_bei_ratte * p_ratte) + (p_schlecht_ohne_ratte * (1 - p_ratte))

# 2. Satz von Bayes anwenden (P(A|B))
p_ratte_bei_schlecht = (p_schlecht_bei_ratte * p_ratte) / p_schlecht_total
print(f"Wahrscheinlichkeit für Ratte bei schlechter Bewertung: {p_ratte_bei_schlecht:.4f}")
```

```
# --- FEHLER 1. ART UND 2. ART (Alpha & Beta) ---
# Fehler 1. Art (Alpha): Du sagst "Prozess ist kaputt" (H1), obwohl alles passt (H0).
# Fehler 2. Art (Beta): Du sagst "Alles passt" (H0), obwohl der Prozess kaputt ist (H1).

# Führe einen t-Test durch (Sollwertprüfung)
test = pg.ttest(df['length'], 115)

# Werte aus dem Test extrahieren
p_val = test['p-val'].values[0]
power = test['power'].values[0] # Teststärke entspricht 1 - Beta

alpha = 0.05 # Festgelegtes Signifikanzniveau
beta = 1 - power # Wahrscheinlichkeit für Fehler 2. Art

# Logik zur Identifikation des Fehlerrisikos
if p_val < alpha:
    print("H0 wird abgelehnt. Signifikanter Unterschied.")
    print(f"Mögliches Risiko: Fehler 1. Art. Wahrscheinlichkeit maximal: {alpha}")
else:
    print("H0 wird beibehalten. Kein signifikanter Unterschied.")
    print(f"Mögliches Risiko: Fehler 2. Art. Wahrscheinlichkeit: {beta:.4f}")
```

```
# Einzelne Spalte extrahieren
total_price = ChristmasSales['TotalPrice']
# Mehrere Spalten auswählen (beachte die doppelten Klammern [[ ]])
df_klein = ChristmasSales[['UnitPrice', 'Quantity', 'UnitPrice']]
#Daten Filtern
df_food = ChristmasSales[ChristmasSales['Category'] == 'Food']
df_teuer = ChristmasSales[ChristmasSales['TotalPrice'] > 100]
df_mix = ChristmasSales[(ChristmasSales['Category'] == 'Food') & (ChristmasSales['Quantity'] > 5)]

#Bedingte Häufigkeit
# 1. Bedingung: Kategorie ist 'Food' -> Wie hoch ist der Anteil 'WAHR' (eingepackt)?
# Wir fixieren die Kategorie 'Food' (Zeile) und schauen auf das Geschenkpapier.
print(pd.crosstab(ChristmasSales['Category'], ChristmasSales['GiftWrap'], normalize='index').loc['Food', 'WAHR'])

# 2. Bedingung: Artikel ist 'FALSCH' (unverpackt) -> Wie hoch ist der Anteil 'Decorations'?
# Wir fixieren den Status 'unverpackt' (Zeile) und schauen auf die Kategorie.
print(pd.crosstab(ChristmasSales['GiftWrap'], ChristmasSales['Category'], normalize='index').loc['FALSCH', 'Decorations'])

# 3. Bedingung: Artikel ist 'WAHR' (eingepackt) -> Wie hoch ist der Anteil 'NICHT Toys'?
# Wir berechnen 1 minus den Anteil von Toys innerhalb der eingepackten Artikel.
print(1 - (pd.crosstab(ChristmasSales['GiftWrap'], ChristmasSales['Category'], normalize='index').loc['WAHR', 'Toys']))
#normalize='index': Berechnet die Häufigkeit relativ zur Zeile (die Bedingung steht vorne in der Klammer).
#.loc[Zeile, Spalte]: Greift gezielt auf den berechneten Prozentwert zu.
```

```
#Zusammenhang kategorialer Merkmale
# Kreuztabelle erstellen
Kreuztab = pd.crosstab(ChristmasSales['Weather'], ChristmasSales['Category'])

# Pearson Koeffizient berechnen
pearson = contingency.association(KreuztabAufgabeC, method='pearson')

# Korrekturfaktor berechnen (nExpr ist die kleinere Anzahl von Zeilen oder Spalten)
nExpr = min(Kreuztab.shape)
c_korr = pearson * np.sqrt(nExpr / (nExpr - 1))

print(f'Pearson korrigiert: {c_korr:.4f}')
#c_korr liegt zwischen 0 und 1.
#0: Kein Zusammenhang zwischen beider Merkmale
#0,1 - 0,3: schwacher Zusammenhang
#0,3 - 0,5: Mittlerer Zusammenhang
# >0,5: Starker Zusammenhang
#1: Perfekter Zusammenhang
```

```
# BINOMIALVERTEILUNG (Ziehen mit Zurücklegen)
# n=Versuche, p=Wahrscheinlichkeit, k=Treffer
p_genau_k = binom.pmf(k, n, p) # Genau k Treffer
p_max_k = binom.cdf(k, n, p) # Höchstens k Treffer
p_mind_k = 1 - binom.cdf(k-1, n, p) # Mindestens k Treffer (Gegenereignis)

# NORMALVERTEILUNG (norm)
# loc = Mittelwert (mu), scale = Standardabweichung (sigma)
prob = norm.cdf(x, loc=110, scale=5) # Wahrscheinlichkeit für Wert <= x
wert = norm.ppf(0.95, loc=110, scale=5) # Welcher Wert schneidet die unteren 95% ab?

# T-VERTEILUNG (wichtig bei kleinen Stichproben n < 30)
# df = Freiheitsgrade (n-1)
t_wert = t.ppf(0.975, df=29) # Kritischer t-Wert für zweiseitiges 95% KI

# HYPERGEOMETRISCHE VERTEILUNG (Ziehen ohne Zurücklegen, z.B. Qualitätskontrolle)
# M: Gesamtanzahl Objekte, n: Anzahl Objekte mit Eigenschaft, N: gezogene Stichprobe
p_hyper = hypergeom.pmf(k, M, n, N)

# CHI-QUADRAT TEST (Unabhängigkeitstest)
# Prüft, ob zwei kategoriale Variablen (z.B. Weather/Category) unabhängig sind
chi2_stat, p_val, dof, expected = contingency.chi2_contingency(Kreuztab)
print(f"p-Wert des Tests: {p_val:.4f}")
# p < 0.05 -> Zusammenhang ist signifikant (nicht zufällig)

# 1. Sollwert-Test bei BEKANNTEM Sigma (Z-Test)
# Man nutzt norm, da die Standardabweichung der Grundgesamtheit bekannt ist.
z_stat = (df['Spalte'].mean() - sollwert) / (sigma / np.sqrt(len(df)))
p_val = 2 * (1 - norm.cdf(abs(z_stat))) # Zweiseitig

# 2. Sollwert-Test bei UNBEKANNTEM Sigma (t-Test)
# Standardfall in den Übungen. Sigma wird durch die Stichprobe geschätzt.
# Nutzt pg.ttest (liefert p-val und Konfidenzintervall automatisch)
test = pg.ttest(df['length'], 115) # 115 ist der Sollwert

# KonfInter für Mittelwert (mu) bei geschätztem Sigma
# Nutzt die t-Verteilung. confint liefert Unter- und Obergrenze.
ki_mu = pg.ttest(df['length'], 0).confint

# KonfInter für Standardabweichung (sigma) - 95%
# Basiert auf der Chi-Quadrat-Verteilung.
n = len(df)
s2 = df['length'].var()
df_deg = n - 1
# Grenzen berechnen
chi2_low, chi2_high = chi2.interval(0.95, df=df_deg)
sigma_lower = np.sqrt(df_deg * s2 / chi2_high)
sigma_upper = np.sqrt(df_deg * s2 / chi2_low)
print(f"95% KI für Sigma: [{sigma_lower:.4f}, {sigma_upper:.4f}]")

Z-Test: $mu$ prüfen, wenn $sigma$ der gesamten Fabrik/Population bekannt ist.
t-Test: $mu$ prüfen, wenn du $sigma$ erst aus deinen Daten berechnen musst.
KI Sigma: Bereich, in dem die echte Streuung der Produktion liegt.
Stichprobenumfang: Verhindert, dass du zu wenige Daten für eine sichere Aussage hast.
Je kleiner der Fehler $e$ sein soll, desto größer muss $n$ sein.
```

SCHLIESSENDE STATISTIK
Du nutzt eine kleine Stichprobe für sichere Aussagen über die große Grundgesamtheit.

- Punktschätzer. Du schätzt einen unbekannten Wert der Realität mit einem einzigen berechneten Wert aus deinen Daten. Der Stichprobenmittelwert schätzt den echten Erwartungswert der Grundgesamtheit.
- Konfidenzintervall. Ein Punktschätzer ist selten exakt. Das Konfidenzintervall liefert einen Bereich. Der echte Wert liegt mit einer definierten Sicherheit in diesem Bereich. Bei einem 95 Prozent Intervall bist du dir zu 95 Prozent sicher.
- Hypothesentest. Du triffst eine mathematische Annahme über die Realität. Diese Annahme ist die Nullhypothese. Die Gegenthese ist die Alternativhypothese. Der Test prüft deine Daten strikt gegen die Nullhypothese.
- Fehler erster Art. Du lehnt die Nullhypothese ab. In Wahrheit stimmt sie. Du schlägst falschen Alarm. Die Wahrscheinlichkeit dafür definierst du als Signifikanzniveau Alpha.
- Fehler zweiter Art. Du behältst die Nullhypothese bei. In Wahrheit ist sie falsch. Du übersiehst einen echten Effekt. Die Wahrscheinlichkeit dafür nennt sich Beta.
- p Wert. Dieser Wert ist das direkte Ergebnis deines Tests. Er zeigt die Wahrscheinlichkeit für deine Daten unter der Annahme der Nullhypothese. Ist der p Wert kleiner als dein Signifikanzniveau Alpha, verwirfst du die Nullhypothese. Du erzielst ein signifikantes Ergebnis.

SKALENNIVEAUS UND DATENTYPEN Daten haben unterschiedliche Niveaus. Das Niveau bestimmt die möglichen Berechnungen. - Nominalskala. Diese Daten sind Namen oder Kategorien ohne logische Reihenfolge. Ein Durchschnitt ergibt keinen Sinn. Beispiele sind Farben, Geschlecht oder Postleitzahlen. - Ordinalskala. Diese Daten haben eine logische Rangfolge. Die Abstände zwischen den Stufen sind undefiniert. Ein Beispiel sind Schulnoten. Eine Note 1 ist besser als eine 2. Der Abstand zwischen 1 und 2 ist nicht zwingend gleich wie zwischen 3 und 4. - Metrische Skala. Diese Daten sind Zahlenwerte mit definierten Abständen. Du berechnest Durchschnitt und Streuung. Beispiele sind Länge, Gewicht oder Preis.	GRUNDLAGEN DER WAHRSCHEINLICHKEIT Ein Zufallsexperiment hat mögliche Ergebnisse. Die Menge aller Ergebnisse ist der Ergebnisraum. Ein Ereignis ist eine exakte Teilmenge davon. - Additionssatz. Er berechnet die Wahrscheinlichkeit für Ereignis A oder Ereignis B. Du addierst beide Wahrscheinlichkeiten und zieht die Schnittmenge ab. Treten A und B nie gleichzeitig ein, fällt die Schnittmenge weg. - Bedingte Wahrscheinlichkeit. Sie beschreibt die Wahrscheinlichkeit von Ereignis A unter der fixen Bedingung von Ereignis B. Vorwissen verändert die Chance. - Unabhängigkeit. Zwei Ereignisse sind unabhängig. Das Eintreten des einen beeinflusst das andere nicht. Die Gesamtwahrscheinlichkeit ist das Produkt der Einzelwahrscheinlichkeiten. - Totale Wahrscheinlichkeit. Sie berechnet die Gesamtwahrscheinlichkeit eines Ereignisses über verschiedene mögliche Pfade. - Satz von Bayes. Diese Formel kehrt bedingte Wahrscheinlichkeiten um. Du kennst die Wahrscheinlichkeit für ein Symptom bei einer Krankheit. Du berechnest damit die Wahrscheinlichkeit für die Krankheit bei genau diesem Symptom.
VERTEILUNGSFORMEN Daten verteilen sich in bestimmten Mustern. Du misst die exakte Form dieser Verteilung. - Schiefe. Sie beschreibt die Asymmetrie der Daten. Ein Wert von 0 bedeutet eine exakt symmetrische Verteilung. Ein negativer Wert bedeutet eine linksschiefe Verteilung. Die Masse der Daten liegt auf der rechten Seite. Ein positiver Wert bedeutet eine rechtsschiefe Verteilung. Die Masse der Daten liegt auf der linken Seite. - Wölbung. Sie beschreibt die Spitzigkeit der Verteilung im Vergleich zur Normalverteilung. Ein positiver Wert bedeutet eine extrem spitze Kurve mit dicken Rändern. Die Werte konzentrieren sich stark um den Mittelwert.	ZUFALLSVARIABLEN UND GRENZWERTSÄTZE Eine Zufallsvariable wandelt ein Ereignis in eine Zahl um. - Erwartungswert. Dies ist der theoretische Durchschnittswert bei unendlich vielen Wiederholungen. Bei einem fairen Würfel liegt dieser Wert bei 3.5. - Gesetz der großen Zahlen. Du wiederholst ein Experiment oft. Der berechnete Durchschnitt nähert sich dem echten Erwartungswert immer genauer an. - Zentraler Grenzwertsatz. Du addierst viele unabhängige Zufallsvariablen oder bildest den Durchschnitt. Das Ergebnis nähert sich einer Normalverteilung an. Das gilt vollkommen unabhängig von der ursprünglichen Verteilung der Daten. Du benötigst eine ausreichend große Stichprobe. Die Regel verlangt mindestens 30 Datenpunkte.

Der zentrale Grenzwertsatz besagt, dass die Summe oder der Durchschnitt einer großen Anzahl von unabhängigen Zufallsvariablen annähernd normalverteilt ist. Dies gilt unabhängig davon, welche Verteilung die ursprünglichen Variablen hatten. Dabei muss der Datensatz eine groß genug Größe haben (n>30)

```
ChristmasSales = pd.read_csv("Christmas Sales and Trends.csv", sep=';', decimal=',')
display(ChristmasSales.head(3))
display(ChristmasSales.tail(3))
```

```
#für metrische Merkmale erkennen
ChristmasSales.describe()
```

```
#häufigkeitsdiagramm TotalPrice
ChristmasSalesTotalPrice = ChristmasSales['TotalPrice']
display(ChristmasSalesTotalPrice.head(3))
```

```
sn.ecdfplot(data=ChristmasSalesTotalPrice)
```

```
plt.title('Kumuliertes Häufigkeitsdiagramm: TotalPrice')
plt.xlabel('Gesamtpreis')
plt.ylabel('Kumulierte Häufigkeit')
plt.grid(True)
plt.show()
print(f"Der Mindestwert der oberen 10% ist: {ChristmasSalesTotalPrice.quantile(0.9)}")
```

```
#Boxplot basierend auf Dicount Amount und Event
plt.figure(figsize=(24, 6))
sn.boxplot(data=ChristmasSales, x='DiscountAmount', y='Event')
plt.show()
```

```
#Boxplot basierend auf Dicount Amount und Event
plt.figure(figsize=(24, 6))
sn.boxplot(data=ChristmasSales, x='DiscountAmount', y='Event')
plt.show()
```

```
print("Kreuztabelle Giftwrap und Category")
KreuztabAufgabeA = pd.crosstab(ChristmasSales['GiftWrap'],ChristmasSales['Category'], margins = True)
print(KreuztabAufgabeA)
```

```
print("bedingte Häufigkeiten")
```

```
print("Food wird eingepackt:")
print(pd.crosstab(ChristmasSales['Category'], ChristmasSales['GiftWrap'], normalize='index').loc['Food', 'WAHR'])
print("unverpackt und aus Kategorie Decoration:")
print(pd.crosstab(ChristmasSales['GiftWrap'], ChristmasSales['Category'], normalize='index').loc['FALSCH', 'Decorations'])
print("eingepackt und nicht Kategorie Toys:")
print(1-(pd.crosstab(ChristmasSales['GiftWrap'], ChristmasSales['Category'],normalize = 'index' ).loc['WAHR','Toys']))
```

```
print("Kontingenzkoeffizient bestimmen und Ableiten")
KreuztabAufgabeC = pd.crosstab(ChristmasSales['Weather'], ChristmasSales['Category'], margins = True)
pearson = contingency_association(KreuztabAufgabeC,method='pearson')
nExpr = n(pd.crosstabAufgabeC.shape)
c_korr = pearson * np.sqrt(nExpr / (nExpr - 1))
print(f"Pearson korrigiert: {c_korr:.4f}")
#Je kleiner Wert desto weniger Zusammenhang
Ergebnis = []
for wL in range(1,7):
    for wD in range(1,7):
        Ergebnis.append(wL*wD)
Augensummen = pd.Series(Ergebnis).value_counts().sort_index()
```

```
x = Augensummen.index.values
absH = Augensummen.values
relH = absH/36
```

```
dataWurfel = pd.DataFrame(data={
    "Summe Augenzahl":x,
    "Abs. Häufigkeit":absH,
    "Rel. Häufigkeit":relH
})
```

```
print(dataWurfel)
```

```
# Es muss immer der Einsatz Abgezogen werden:
# Gewinn bei Augensumme 2: 16 - 3 = 13
# Gewinn bei Augensumme 11: 15 - 3 = 12
# Gewinn bei Augensumme 12: 15 - 3 = 12
# Gewinn restliche Augensummen: 0 - 3 = -3
Erwartungswert = (Gewinn mit rel. Häufig multipliziert je Augensumme und addiert)
print(f"Der Erwartungswert ergibt: {Erwartungswert:.4f}")
```

```
print("Boxplot Länge nach Gruppe")
Rotor = pd.read_csv('Rotorblätter.csv')
display(Rotor.head(3))
```

```
# y ist die Länge, x die Gruppierung, hue sorgt für verschiedene Farben
sn.boxplot(data=Rotor, x='group', y='length', hue='group')
plt.show()
```

```
print("Konfidenzintervalle")
# Berechnet Mittelwert, Standardfehler und Konfidenzintervalle pro Gruppe von Variable length
ci_tabelle = Rotor.groupby('group')[['length']].apply(lambda x: pg.ttest(x, 0)).reset_index()
print(ci_tabelle[['group', 'estimate', 'confint']])
print("Das Intervall gibt den Bereich an, in dem der wahre Mittelwert der "
      "Grundgesamtheit mit 95% Wahrscheinlichkeit liegt. "
      "Überlappen sich die Intervalle der Gruppen nicht, ist der Längenunterschied "
      "zwischen ihnen statistisch signifikant.")
```

```
print("Hypothesentest ob Produktion neu kalibriert werden muss")
```

```
# Test gegen den festen Sollwert von 115 mit signifikanzniveau alpha = 0.05
test_ergebnis = pg.ttest(Rotor['length'], 115)
p_val = test_ergebnis['p-val'].values[0]
print(f"P-Wert: {p_val:.4f}")
if p_val < 0.05:
    print("Die Produktion weicht signifikant von 115m ab. Neukalibrierung nötig.")
else:
    print("Keine signifikante Abweichung festgestellt. Keine Neukalibrierung nötig.")
```

```
college = pd.read_csv('college.csv')
display(college.head(3))
```

```
print(f"n = {n}")
# Berechnet Korrelationskoeffizienten zu 'Apps', sortiert sie absteigend und nimmt die Top 3 (ohne 'Apps' selbst)
top_3 = college.sort(columns=['Apps'], sort_values=ascending).loc[1:4]
```

```
print(f"n = {n}")
# Regressionsmodell
# Daten vorbereiten (nur numerische Daten nutzen)
df_num = college.select_dtypes(include=(np.number))
n = df_num.shape[0]
y = df_num['Apps']
# Split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
# Modell mit Konstante erstellen
X_train_const = np.ones((n_train,1))
model = sm.OLS(y_train, X_train_const).fit()
```

```
print(model.summary())
# Interpretation der Qualitäts-P-Werte (P-Value): Merkmale mit einem Wert unter 0.05 sind statistisch signifikant R-squared:
# Gibt an, wie viel Prozent der Streuung der Beobachtungen durch das Modell erklärt werden P-Statistik: Prüft, ob das Modell
# als Ganzes besser ist als ein Modell ohne Variablen.
c) Interpretation von R^2 (adj) = 0.918
Ein Wert von 0.918 bedeutet, dass 91,8 % der Varianz der Zielvariablen (Apps) durch die unabhängigen Merkmale im Modell erklärt werden.
Das Modell weist eine sehr hohe Güte auf, die Vorhersagen liegen nah an den tatsächlichen Werten. Das 'adj' (adjustiert) bedeutet,
dass dieser Wert für die Anzahl der verwendeten Merkmale korrigiert wurde.
Er ist somit aussagekräftiger als das normale R^2, da er "Reststrafungen" für unnötige Variablen enthält.
```